

# Guia Completo de Apresentação para Banca de Doutorado

Jefferson Bezerra dos Santos

*Robótica Probabilística*

## 1 Introdução

Este documento reúne todas as orientações práticas, estratégicas, comportamentais e científicas necessárias para uma apresentação de doutorado de alto nível.

Seu objetivo é servir como **manual de estudo**, fornecendo:

- Estrutura ideal da apresentação oral;
- Como se comportar diante da banca;
- Metodologia explicada de forma clara e sólida;
- Roteiro detalhado de fala;
- Estratégias de respostas para perguntas difíceis;
- Pontos fortes do projeto de pesquisa;
- Justificativas científicas e técnicas;
- Diretrizes para seu Beamer.

## 2 Estrutura Ideal da Apresentação

A apresentação deve ter duração entre 15 e 20 minutos. A organização recomendada segue:

1. Abertura (1 minuto)
2. Justificativa (2 minutos)
3. Revisão da Literatura (3 minutos)
4. Objetivos Geral e Específicos (2 minutos)
5. Metodologia (6 minutos)
6. Contribuições Esperadas (1 minuto)
7. Encerramento (30 segundos)

Cada parte é explicada detalhadamente nas próximas seções.

## 3 1. Abertura da Apresentação

A banca avalia o início da apresentação como um indicador de segurança e domínio.

### 3.1 Frase Recomendada

*“Bom dia a todos. Meu nome é Jefferson Bezerra dos Santos e apresento hoje minha proposta de pesquisa intitulada **Robótica Probabilística**, com foco em métodos bayesianos para estimativa de estado e classificação em plataformas embarcadas.”*

### 3.2 Objetivo da abertura

- Demonstrar clareza;
- Mostrar objetividade;
- Indicar domínio sem arrogância.

## 4 2. Justificativa da Pesquisa

A justificativa é o momento para explicar **por que sua pesquisa é necessária**.

### 4.1 Problemas Reais da Robótica

- Incerteza sensorial (ruído, imprecisão);
- Incerteza na atuação (derrapagem, erros nos motores);
- Ambientes imprevisíveis e dinâmicos.

### 4.2 Enfoque Científico

**Robôs nunca têm acesso ao estado verdadeiro do mundo.** Essa frase, dita com convicção, impressiona a banca.

### 4.3 Justificativa Central

O uso de abordagens probabilísticas permite:

- modelagem formal de incertezas;
- decisões mais confiáveis;
- fusão sensorial robusta;
- execução em hardware limitado.

## 5 3. Revisão da Literatura

Uma boa revisão não cita apenas autores; ela expõe **lacunas científicas**.

### 5.1 Principais Referências

- Thrun et al. (2005) – base teórica da robótica probabilística;
- Särkkä (2013) – filtros bayesianos;
- Redes Neurais Bayesianas (2020–2025);
- Meta-aprendizado bayesiano.

### 5.2 Lacuna da Literatura

Falta um framework unificado que combine **filtros bayesianos** e **classificadores probabilísticos executando de forma eficiente** em plataformas embarcadas de baixo custo.

Essa é sua contribuição potencial.

## 6 4. Objetivos

### 6.1 Objetivo Geral

Desenvolver e implementar métodos de robótica probabilística com ênfase em filtros bayesianos e classificadores para robôs embarcados.

### 6.2 Objetivos Específicos

1. Modelar matematicamente as incertezas sensoriais e de atuação;
2. Implementar filtros para fusão de dados e estimativa de estado;
3. Desenvolver classificadores probabilísticos para tomada de decisão;
4. Otimizar esses métodos para execução em microcontroladores.

## 7 5. Metodologia

Esta é a parte mais analisada pela banca. A seguir está uma versão expandida, organizada e convincente tanto para leitura quanto para apresentação oral.

## 7.1 5.1 Visão Geral da Metodologia

A metodologia é estruturada em quatro camadas principais:

1. **Modelagem Probabilística do Sistema** Definição dos modelos de movimento e observação.
2. **Estimativa Recursiva de Estado** Aplicação de filtros bayesianos (Kalman, EKF, PF).
3. **Classificação Probabilística** Uso de Naive Bayes ou Redes Bayesianas para tomada de decisão.
4. **Otimização Computacional** Adaptação dos algoritmos para execução em microcontroladores.

Durante a apresentação, você dirá:

*“O foco da metodologia é construir um pipeline probabilístico capaz de lidar com incertezas e ainda assim ser leve o suficiente para rodar em hardware embarcado.”*

## 7.2 5.2 Modelagem Matemática das Incertezas

A robótica probabilística assume que:

- sensores são ruidosos;
- atuadores não são perfeitos;
- o estado real nunca é observado diretamente.

Assim, representamos o estado por uma **distribuição de probabilidade**, não por um valor único.

### 7.2.1 Modelo de Movimento

$$p(x_t | u_t, x_{t-1})$$

Interpretação para a banca:

*“O modelo de movimento prediz onde o robô deveria estar, mas sempre com incerteza acumulada.”*

### 7.2.2 Modelo de Observação

$$p(z_t | x_t)$$

Interpretação:

*“O modelo de observação diz quão provável é um sensor medir determinado valor, dado o estado real.”*

## 7.3 5.3 Filtro Bayesiano — Estrutura Completa

O filtro bayesiano é o mecanismo central da minha metodologia. Ele permite que o robô estime seu estado mesmo quando sensores e atuadores são imprecisos.

Ele funciona em dois passos. No passo de predição, uso o modelo de movimento para projetar a crença anterior para o instante atual, incorporando o comando de controle e seu respectivo erro. Isso gera a crença prévia, onde o robô acha que está antes de olhar para os sensores.

No passo de correção, comparo essa predição com a medição do sensor através do modelo de observação, que calcula quão consistente é aquela medição para cada estado possível. Multiplico essa coerência pela crença prévia e normalizo a distribuição.

O resultado final é a crença posterior, uma estimativa probabilística completa sobre onde o robô está. Essa abordagem é fundamental porque robôs nunca observam diretamente o estado real; eles sempre operam sob incerteza, e o filtro bayesiano é a forma matematicamente correta de lidar com isso.”

### 7.3.1 Predição

$$\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

*“A predição projeta a crença anterior para frente, incorporando a incerteza do movimento.”*

### 7.3.2 Correção

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

*“A correção ajusta essa crença usando o sensor.”*

### 7.3.3 Filtro Bayesiano: Explicação Termo a Termo

O filtro bayesiano é o núcleo matemático da robótica probabilística. Seu objetivo é estimar o estado real do robô mesmo quando sensores são ruidosos e atuadores são imprecisos. Ele opera de forma recursiva, em dois passos: predição e correção. A seguir, apresenta-se a explicação completa de cada termo envolvido nas equações fundamentais.

#### Equação de Predição

$$\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

**1.  $bel(x_{t-1})$  — Crença Anterior** Representa a distribuição de probabilidade sobre o estado no instante anterior. É o conhecimento acumulado até o tempo  $t - 1$ . Não é um valor único, mas sim toda a incerteza do robô antes da etapa atual.

**2.  $u_t$  — Comando de Controle** Corresponde à ação aplicada ao robô (velocidade, rotação, aceleração). O filtro assume que essa ação contém incertezas, como derrapagens ou erros de motor.

**3.  $p(x_t | u_t, x_{t-1})$  — Modelo de Movimento** É a probabilidade de o robô transitar do estado  $x_{t-1}$  para  $x_t$  após executar  $u_t$ . Modela formalmente o erro dos atuadores e a imprevisibilidade do movimento.

**4. A Integral  $\int(\dots) dx_{t-1}$**  A integral combina todas as possíveis posições anteriores ponderadas por suas probabilidades. Ela propaga toda a incerteza do passado para o futuro, gerando uma predição estatística consistente.

**5.  $\overline{bel}(x_t)$  — Crença Prévia** É a crença do robô antes de considerar a medição do sensor. Representa o que se espera sobre o estado após aplicar o comando, mas ainda sem informações sensoriais.

### Equação de Correção

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

**6.  $z_t$  — Medição do Sensor** É o valor capturado pelo sensor no instante  $t$ . Pode ser leitura de distância, cor, temperatura, profundidade, etc. Cada um desses sensores contém ruído que deve ser modelado probabilisticamente.

**7.  $p(z_t | x_t)$  — Modelo de Observação** Informa a probabilidade de observar  $z_t$  caso o robô esteja realmente no estado  $x_t$ . Mede a consistência entre a predição e o sensor, filtrando leituras ruidosas.

**8.  $\eta$  — Constante de Normalização** Garante que a soma total da distribuição resultante seja igual a 1. Sem essa constante, a função resultante não seria uma distribuição de probabilidade válida.

**9.  $bel(x_t)$  — Crença Posterior** É a crença final do robô sobre seu estado no instante  $t$ , já corrigida com a medição. Essa distribuição será usada como crença anterior no próximo ciclo do filtro.

### Interpretação Conceitual

O filtro bayesiano combina duas fontes de informação:

- conhecimento prévio (movimento + crença passada);

- evidência sensorial atual.

A fusão dessas duas partes produz uma estimativa robusta e matematicamente fundamentada, essencial para robôs operando sob incerteza.

Na apresentação, dizer:

## 7.4 5.4 Métodos Considerados

- **Filtro de Kalman** — eficiente, mas assume linearidade.
- **EKF** — linearização; bom para robôs móveis.
- **Filtro de Partículas** — mais flexível, porém mais pesado.

Na apresentação, dizer:

*“A principal decisão metodológica é equilibrar robustez estatística e custo computacional.”*

## 7.5 5.5 Classificador Probabilístico

O classificador atribui categorias às entradas sensoriais:

$$P(C_k|\mathbf{x}) \propto P(C_k) \prod_{i=1}^n P(x_i|C_k)$$

Vantagens para robótica embarcada:

- Independência condicional reduz custos;
- Atualização rápida;
- Fácil de calibrar;
- Probabilístico: combina diretamente com o filtro.

## 7.6 Classificador Probabilístico na Metodologia

O classificador probabilístico desempenha um papel complementar ao filtro bayesiano dentro da arquitetura proposta. Enquanto o filtro estima o estado contínuo do robô (posição, orientação, variáveis ambientais), o classificador é responsável pela tomada de decisão discreta, atribuindo cada conjunto de leituras sensoriais a uma categoria ou evento de interesse.

### Modelo Probabilístico

O classificador é baseado na regra de Bayes aplicada à tarefa de decisão:

$$P(C_k | \mathbf{x}) \propto P(C_k) \prod_{i=1}^n P(x_i | C_k)$$

onde:

- $C_k$  representa uma classe ou categoria possível (ex.: tipo de terreno, condição ambiental, estado operacional do robô);
- $\mathbf{x} = (x_1, x_2, \dots, x_n)$  são as leituras sensoriais recebidas no instante atual;
- $P(C_k)$  é a probabilidade a priori da classe;
- $P(x_i | C_k)$  é a verossimilhança da leitura  $x_i$  caso a classe seja verdadeira;
- o produto assume independência condicional entre sensores, característica essencial para execução em hardware embarcado de baixo custo.

## Motivação Dentro da Pesquisa

O classificador probabilístico foi escolhido devido a:

- baixo custo computacional;
- atualização rápida e recursiva;
- compatibilidade direta com a filosofia Bayesiana da pesquisa;
- robustez a ruídos sensoriais;
- excelente adaptação para microcontroladores.

Na arquitetura proposta, o classificador recebe como entrada:

1. as medições sensoriais brutas (ex.: TDS, turbidez, cor, temperatura);
2. ou as estimativas suavizadas geradas pelo filtro bayesiano.

Essa integração permite decisões mais confiáveis, pois reduz a influência de leituras irregulares.

## Fluxo Operacional

O funcionamento do classificador dentro do sistema segue quatro etapas principais:

1. **Coleta de Dados:** leitura dos sensores embarcados;
2. **Normalização:** padronização e preparação das entradas;
3. **Cálculo das probabilidades:** avaliação das verossimilhanças e da probabilidade posterior para cada classe;
4. **Decisão:** seleção da classe com maior probabilidade posterior.

## Integração com o Filtro Bayesiano

A integração ocorre em duas direções:

- O classificador utiliza a crença estimada pelo filtro como informação contextual adicional;
- O resultado do classificador retroalimenta a estimativa de estado, permitindo correções baseadas em eventos discretos.

Assim, obtém-se um sistema híbrido contínuo-discreto que combina percepção e tomada de decisão sob incerteza.

## Justificativa Científica

A opção por um classificador probabilístico, em vez de abordagens determinísticas ou redes profundas complexas, se justifica pela natureza da pesquisa:

- A robótica probabilística exige representações explícitas de incerteza.
- A transparência matemática das distribuições probabilísticas é fundamental.
- Microcontroladores possuem severas limitações de memória e processamento.
- A regra de Bayes garante consistência teórica entre percepção e decisão.

## Explicação Oral Recomendada:

Ele usa a regra de Bayes para calcular a probabilidade de cada categoria, dado o conjunto de sensores. Isso é importante porque os sensores têm ruído, e o classificador consegue incorporar essa incerteza naturalmente.

Além disso, ele é extremamente leve computacionalmente, então pode ser executado em microcontroladores sem perda de desempenho. Essa escolha mantém toda a arquitetura probabilística coerente, desde a percepção até a decisão final.”

## 7.7 5.6 Integração Filtro + Classificador

Na minha pesquisa unifica duas camadas tradicionalmente separadas:

1. **Percepção** — estimativa contínua de estado;
2. **Decisão** — classificação probabilística.

Ambas compartilham:

- mesma representação probabilística;
- mesma base teórica (regra de Bayes);
- mesmas estratégias de otimização computacional.

## 7.8 5.7 Otimização para Hardware Embarcado

Pontos que a banca valoriza:

- quantização de variáveis;
- redução da dimensionalidade;
- pré-cálculo de tabelas de probabilidade;
- uso de estruturas matemáticas leves;
- implementação em C/C++ otimizada.

Fala recomendada:

*“O desafio é manter rigor probabilístico sem ultrapassar os limites de memória e processamento do microcontrolador.”*

## 8 6. Contribuições Esperadas

- Framework probabilístico leve para robôs de baixo custo;
- Algoritmos otimizados para microcontroladores;
- Integração filtro + classificador;
- Avanços para navegação robusta.

## 9 7. Comportamento Diante da Banca

### 9.1 Postura

- Fale devagar e com clareza;
- Evite ler slides;
- Use pausas estratégicas;
- Mantenha contato visual;
- Mostre segurança, não arrogância.

### 9.2 Frases que transmitem maturidade

- “Este ponto está em desenvolvimento, mas já temos diretrizes claras.”
- “Essa é uma excelente pergunta.”
- “Planejo investigar isso na etapa experimental.”

## 10 8. Como Responder Perguntas Difíceis

### 10.1 Estratégia em Três Etapas

1. Reconheça a pergunta
2. Responda objetivamente
3. Conecte à pesquisa

### 10.2 Se não souber responder

Diga:

“Ainda não tenho esse resultado, mas isso se alinha à próxima etapa da pesquisa, onde investigarei exatamente esse comportamento.”

## 11 9. Pontos Fortes da Sua Pesquisa

- Integração teórico-prática rara;
- Base sólida na literatura clássica;
- Aplicabilidade em robôs reais;
- Benefício direto para robótica de baixo custo;
- Relevância acadêmica e social.

## 12 Conclusão

Este documento sintetiza todo o necessário para realizar uma apresentação forte, organizada, convincente e cientificamente sólida.

Recomenda-se ler este guia diversas vezes e usá-lo paralelamente aos seus slides em Beamer.