


Robótica Probabilística

Jefferson Bezerra dos Santos



Fonte: ChatGPT (OpenAI, 2025)

Pilares Fundamentais

- **Modelagem** de incertezas sensoriais
- **Estimativa** de estado (filtros bayesianos)
- **Classificadores** atualização do estado
- **Decisão** sob incerteza

Justificativa

Problema

Robôs autônomos operam em ambientes reais caracterizados por:

- Incerteza sensorial (ruído, imprecisão)
- Incerteza de atuação (derrapagem, imprecisão motora)
- Ambientes dinâmicos e imprevisíveis

Solução Proposta

Abordagens probabilísticas oferecem:

- Framework matemático rigoroso para lidar com incertezas
- Estimativas de confiança para decisões
- Robustez em ambientes complexos
- Implementação eficiente em hardware limitado


Revisão da Literatura

Fundamentos Teóricos

- **Teorema de Bayes**
Atualização de crenças
- **Filtros Bayesianos**
Thrun (2005)
- **Classificadores**
Naive Bayes
Redes Bayesianas
Redes Neurais Bayesianas (BNNs)

Principais Contribuições

- **Thrun et al. (2005)**
Probabilistic Robotics
- **Bayesian Meta-Learning for Autonomous Robots (2025)**
Revisão sobre meta-aprendizado bayesiano em robôs autônomos.
- **Bayesian Neural Networks: An Introduction and Survey (2020)**
Introdução abrangente às Redes Neurais Bayesianas.
- **Enhancing Autonomous Systems with Bayesian Neural Networks (2025)**
Aplicação de redes neurais bayesianas em navegação autônoma.



Objetivos

Desenvolver e implementar métodos de robótica probabilística com ênfase em filtros bayesianos e classificadores em plataformas embarcadas

1. Modelar matematicamente as incertezas sensoriais e de atuação em robótica móvel

2. Implementar filtros bayesianos para fusão de dados sensoriais e estimativa de estado

3. Desenvolver classificadores probabilísticos para detecção de obstáculos e tomada de decisão

4. Otimizar os algoritmos para execução eficiente em microcontroladores

Metodologia: Filtros e Classificadores Bayesianos

Filtro Bayesiano

Predição:

$$\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

Correção:

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

- $bel(x_t)$: crença no estado
- u_t : ação de controle
- z_t : medida do sensor
- η : fator de normalização

Naive Bayes

Fórmula:

$$P(C_k | \mathbf{x}) \propto P(C_k) \prod_{i=1}^n P(x_i | C_k)$$

- \mathbf{x} : medições dos sensores
- C_k : classe/estado (ex.: obstáculo)
- $P(C_k)$: probabilidade a priori
- $P(x_i | C_k)$: probabilidade condicional
- \prod : produto das condições

Aplicando o Naive Bayes:

$$P(\text{obstáculo} | \mathbf{X}) = \frac{\prod_{i=1}^2 P(X_i | \text{obstáculo}) P(\text{obstáculo})}{P(\mathbf{X})}$$

$$\mathbf{X} = (d_{\text{ultrassônico}}, d_{\text{infravermelho}})$$

Referências



BARBER, David. *Bayesian Reasoning and Machine Learning*. Cambridge: Cambridge University Press, 2012.



BISHOP, Christopher M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.



JONES, M.; KIM, H.; RAHMAN, S. Enhancing Autonomous Systems with Bayesian Neural Networks. *Frontiers in Built Environment*, 2025.



LEWIS, David D. Naive (Bayes) at Forty: The Independence Assumption in Information Retrieval. In: *ECML*, 1998.



MONTEMERLO, Michael et al. FastSLAM: A Factored Solution to the Simultaneous Localization and Mapping Problem. In: *AAAI*, 2002.



SÄRKKÄ, Simo. *Bayesian Filtering and Smoothing*. Cambridge: Cambridge University Press, 2013.



SMITH, John; FALCON, Robert. Bayesian Neural Networks: An Introduction and Survey. 2020.



THRUN, Sebastian; BURGARD, Wolfram; FOX, Dieter. *Probabilistic Robotics*. Cambridge: MIT Press, 2005.



WANG, Y.; LI, S.; ZHOU, X. Bayesian Meta-Learning for Autonomous Robots. *Journal of Intelligent & Robotic Systems*, 2025.



FOX, Dieter et al. Monte Carlo Localization: Efficient Position Estimation for Mobile Robots. In: *AAAI*, 1999.